GÉODATA APPLIQUÉE · SÉANCE 3

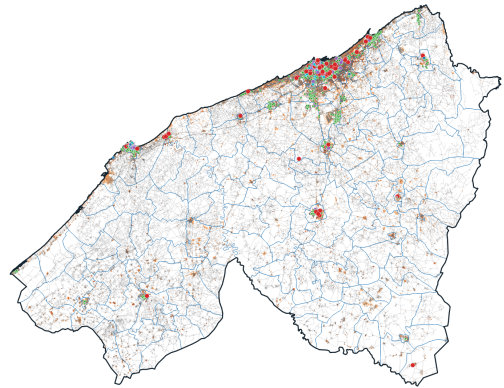
Accès aux soins dans la région Casablanca-Settat

Acquisition des données : un pipeline de collecte reproductible

SOUILAH Meryem · MANYANI Hiba · ZOUHRI Imane

BELMOKHTARE Fatima Ezzahra · GUEROUANE Imane

Élèves ingénieurs 3e année



Déroulé de la présentation

01 **Le défi et la phase**
question, consignes, organisation

02 **Sources et pipeline**
5 sources, architecture, choix techniques

03 **Résultats et vérification**
jeu de données, contrôle, carte, QGIS

04 **Reproductibilité**
archive, versions figées, preuve par les tests

05 **Démonstration et suite**
démo live, limites, intersession 3

01

Le défi et la phase

Ce que le projet doit résoudre, et ce que demandait l'intersession 2

LE DÉFI ET LA PHASE

Le défi spatial

QUESTION À RÉSOUDRE

Quelles zones de la région Casablanca-Settat sont mal desservies en établissements de santé, et où faut-il intervenir en priorité ?

Mesurer

Le temps d'accès par la route de la population aux hôpitaux, cliniques, médecins et pharmacies.

Modéliser

Repérer les zones sous-desservies avec un modèle de machine learning.

Recommander

Prioriser les interventions pour la Direction régionale de la Santé, le Conseil régional et les urbanistes.

LE DÉFI ET LA PHASE

Ce que demandait l'intersession 2

Consigne	Notre réponse	
Environnement : QGIS, PostGIS, GDAL/OGR, Python géospatial	QGIS 4.2, PostgreSQL 16, conda	✓
Script Python de collecte, sans aucun clic manuel	`collecte.py`, une commande	✓
Au moins une deuxième source	5 sources ouvertes	✓
`SOURCES.md` : URL, date, licence, CRS, emprise	généré à chaque exécution	✓
`donnees_brutes/` versionné, README de provenance	README + manifeste SHA-256	✓
Capture QGIS des couches superposées	EPSG:26191	✓
Démonstration live du script	aujourd'hui	✓

LE DÉFI ET LA PHASE

Organisation du groupe

LEAD DE L'INTERSESSION 2

MANYANI Hiba

Membre M2 : formule
$((S-2) \bmod 5) + 1$ avec $S = 3$

ROTATION

M1 SOUILAH Meryem · séances 2 et 7
M2 MANYANI Hiba · séance 3
M3 ZOUHRI Imane · séance 4
M4 BELMOKHTARE Fatima Ezzahra · séance 5
M5 GUEROUANE Imane · séance 6

	Sous-tâche	Responsable
A	Script d'acquisition de la source principale	[Nom]
B	Recherche et test des sources complémentaires	[Nom]
C	Vérification CRS / emprise, contrôle	[Nom]
D	README de provenance et versionnement	[Nom]

02

Sources et pipeline

Cinq sources ouvertes, trois scripts, une commande

SOURCES ET PIPELINE

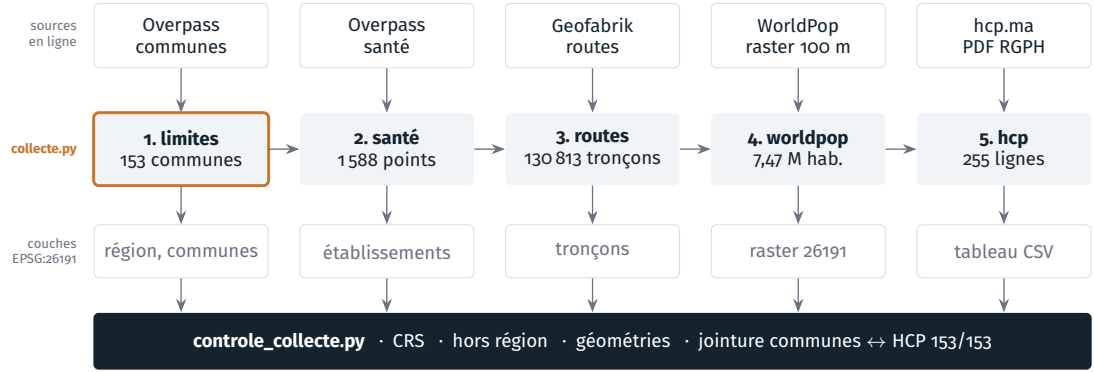
Cinq sources ouvertes, chacune répond à une question

Donnée	Producteur	Question du défi	Millésime	Licence
Communes et contour	OpenStreetMap, codes HCP	Dans quel découpage restituer ?	28/07/2026	ODbL 1.0
Établissements de santé	OpenStreetMap (Overpass)	Où est l'offre de soins ?	24/07/2026	ODbL 1.0
Réseau routier	OpenStreetMap (Geofabrik)	Par où passent les trajets ?	14/10/2026	ODbL 1.0
Population 100 m	WorldPop	Où vit la population, finement ?	2020	CC BY 4.0
Population légale	HCP, RGPH 2024	Quel est le chiffre officiel ?	01/09/2024	Citation

CRS unique de toutes les couches : **EPSG:26191** (Merchich / Nord Maroc, en mètres), pour mesurer distances et temps d'accès.

SOURCES ET PIPELINE

Architecture du pipeline



L'étape **limites** produit le contour régional qui découpe les étapes 2 à 4. Chaque étape réécrit le manifeste, le README de provenance et `SOURCES.md`.

Trois scripts, une commande

`config.py`	URL, emprise, CRS, filtres : un seul endroit
`collecte.py`	Télécharge, découpe, reprojette, documente
`controle_collecte.py`	Vérifie, produit rapport et carte
`run_collecte.bat`	Active l'environnement, enchaîne les deux

ROBUSTESSE

- Serveurs et miroirs essayés tour à tour
- Fichier `.part` renommé à la fin seulement
- Une source en échec n'arrête pas les autres
- Code de sortie 0 seulement si tout est conforme

```
run_collecte.bat                                                    collecte complète + contrôle
run_collecte.bat --force --etapes sante hcp                              retéléchargement réel

python scripts\collecte.py --depuis-archive sauvegarde_sources\...zip    reconstruction exacte
```

SOURCES ET PIPELINE

Trois choix techniques, issus de l'audit des sources

1

Communes OpenStreetMap plutôt que HDX

Le jeu officiel COD-AB du Maroc (HDX) et geoBoundaries s'arrêtent aux provinces. Dans OSM, chaque commune porte son **code HCP** (`06.117.01.03` = Berrechid) : jointure directe avec la population légale.

2

Le PDF des tableaux, pas la note de synthèse

Le premier lien HCP pointait vers une note `.docx` sans tableau communal. Le bon document : PDF de 138 pages ; lignes de la région filtrées par code `06`.

3

Extrait Geofabrik plutôt que 100 requêtes Overpass

Mêmes données OSM, datées, en un fichier : quelques minutes au lieu de plusieurs heures. Pistes conservées : elles desservent une partie des douars ruraux.

03

Résultats et vérification

Un jeu de données complet, contrôlé automatiquement

RÉSULTATS ET VÉRIFICATION

Le jeu de données obtenu

153
communes
9 provinces, code HCP

1 588
établissements
82 hôpitaux, 74 cliniques

130 813
tronçons
53 890 km de voies

7,47 M
habitants
WorldPop, pixels de 100 m

153/153
jointure HCP
population officielle

- Région : **20 207 km²**, union des 153 communes
- 1 734 établissements dans le rectangle de requête, 146 écartés hors région
- 149 134 tronçons lus, 130 813 après découpe au contour
- 255 lignes HCP pour la région, dont 153 communes

RÉSULTATS ET VÉRIFICATION

CRS uniforme, vérifié automatiquement

Couche	CRS	Entités	Invalides	Hors région	
Contour régional	EPSG:26191	1	0	—	✓
Communes	EPSG:26191	153	0	0	✓
Établissements de santé	EPSG:26191	1 588	0	0	✓
Réseau routier	EPSG:26191	130 813	0	0	✓
WorldPop 100 m	EPSG:26191	2186 × 1753 px	—	—	✓

Jointure communes ↔ HCP

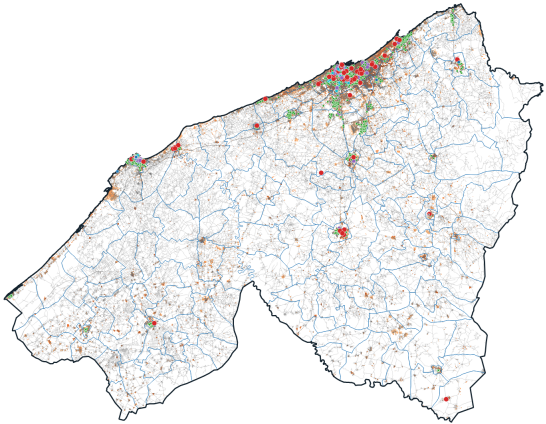
153 communes sur 153 ont leur population officielle.

Reprojection du raster

Rééchantillonnage par **somme** : 7 466 216 hab. avant et après, écart 0,00 %.

RÉSULTATS ET VÉRIFICATION

Toutes les couches, superposées en EPSG:26191



LECTURE

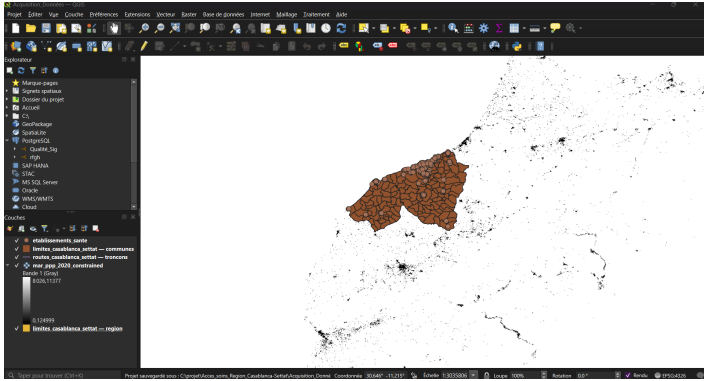
Hôpitaux Communes
Population Routes

Hôpitaux et cliniques se concentrent sur le **littoral** et dans quelques chefs-lieux.

Seules **18 communes sur 153** contiennent un hôpital ; de grandes zones rurales peuplées n'en ont aucun à proximité.

C'est l'hypothèse du défi, que les temps d'accès chiffreront.

Vérification dans QGIS



Projet en EPSG:26191 · Berrechid : `code_hcp = 06.117.01.03` · 168 687 habitants dans le tableau HCP

04

Reproductibilité

Le même jeu de données, aujourd’hui comme dans un an

REPRODUCTIBILITÉ

Trois garanties, pas une

Relancer le script dans un an ne suffit pas : OSM change chaque jour, Geofabrik ne garde que le dernier extrait, une URL peut disparaître.

MÊME CODE

Dépôt Git

Scripts, documentation, requêtes Overpass, tableau HCP.

MÊME ENVIRONNEMENT

Versions figées

`environment.yml` + `requirements-lock.txt` : Python 3.11.17 et les 48 paquets à la version exacte.

MÊMES DONNÉES

Archive des sources

Les fichiers bruts exacts et le manifeste : 547 Mo compressés en 262 Mo. Chaque fichier vérifié par son empreinte **SHA-256**.

```
python scripts\collecte.py --archiver                                  fige les sources brutes
python scripts\collecte.py --depuis-archive sauvegarde_sources\sources_brutes_2026-10-22.zip
```

REPRODUCTIBILITÉ

La preuve : deux reconstructions depuis un dossier vide

	Jeu archivé collecte du 21/10	Depuis l'archive hors ligne, 5 min	Depuis Internet 22/10, 23 min
Communes	153	153	153
Établissements de santé	1 588	1 588	**1 577**
Tronçons routiers	130 813	130 813	**130 856**
Population WorldPop	7 466 216	7 466 216	7 466 216
Jointure HCP	153/153	153/153	153/153
Contrôle	—	✓ code 0	✓ code 0

Le code est reproductible : les deux reconstructions passent le contrôle. **Les sources évoluent** : en un jour, OSM et Geofabrik ont changé. Seule l'archive redonne **exactement** le jeu présenté.

REPRODUCTIBILITÉ

Provenance et versionnement

GÉNÉRÉ À CHAQUE EXÉCUTION

- `SOURCES.md` : URL, licence, millésime, date de téléchargement, CRS d'origine → produit, emprise, volume
- `donnees_brutes/README.md` : fiche par source, fichiers et SHA-256
- `manifest.json` : la même provenance, lisible par machine

Jamais modifiés à la main : ils ne peuvent pas diverger des données.

CE QUE GIT VERSIONNE

- ✓ Code, README, manifeste, `SOURCES.md`
- ✓ Requêtes Overpass, tableau HCP (CSV)
- ✓ Diagrammes UML, projet QGIS
- × Rasters, GeoPackage, extraits OSM

Limite GitHub : 100 Mo par fichier. L'archive est publiée en Release.

05

Démonstration et suite

Le script en direct, puis les limites et l’intersession 3

Démonstration live

1. **Retéléchargement réel, puis contrôle automatique**
   `run_collecte.bat --force --etapes sante hcp`
   Requêtes vers Overpass et hcp.ma ; le chiffre peut varier : OSM évolue

2. **Reconstruction exacte depuis l'archive**
   `collecte.py --depuis-archive sauvegarde_sources\...zip`
   SHA-256 vérifiés, retour à 1 588 et 130 813

3. **Provenance**
   `SOURCES.md` et `donnees_brutes\README.md`
   Millésime, licence, emprise, empreintes

4. **Vérification visuelle**
   `preuves\verification_couches_26191.qgz`
   Superposition en EPSG:26191, code HCP d'une commune

Difficultés rencontrées et solutions

Problème	Cause	Solution
Pas de communes dans les limites HDX	COD-AB Maroc limité aux provinces	Communes OSM avec code HCP
Le « PDF HCP » ne s'ouvrait pas	C'était la note `.docx`, mauvaise URL	PDF des tableaux, signature `%PDF-` vérifiée
Routes : plusieurs heures, délais dépassés	Environ 100 requêtes Overpass saturées	Extrait Geofabrik filtré à la lecture
« EPSG code is unknown »	`PROJ_LIB` de PostgreSQL trop ancien	Correctif automatique dans `config.py`
Chiffres différents d'un jour à l'autre	Sources en ligne qui évoluent	Archive des sources + SHA-256

DÉMONSTRATION ET SUITE

Limites connues des données

Complétude d'OSM

Source contributive : 8,8 % des établissements sans nom ; les pharmacies représentent 79 % des points. À mesurer en phase qualité.

Millésimes différents

Le serveur Overpass utilisé a plusieurs mois de retard (juillet 2026) ; routes au 14/10/2026 ; WorldPop 2020 ; recensement au 1er septembre 2024.

Réseau non topologisé

Les tronçons ne sont pas encore reliés aux intersections ; le graphe routier (ponts, tunnels) se construit au pré-traitement.

WorldPop est une estimation

Il sera calé sur la population légale HCP, commune par commune.

DÉMONSTRATION ET SUITE

Pourquoi une grille hexagonale H3 pour la suite

× 912

surface

de 0,4 à 383 km² selon la commune

× 1 531

population

de 2 101 à 3,2 M d'habitants

18

communes

sur 153 ont un hôpital

27 000

hexagones

résolution 8, 0,74 km² chacun

Une moyenne sur une grande commune rurale **cache les douars isolés**, précisément ceux que le défi doit repérer. Des cellules de même taille rendent chaque mesure comparable et donnent assez d'exemples au modèle.

6 voisins à égale distance, validation croisée spatiale par blocs (`cell_to_parent`), puis agrégation par commune pour les recommandations. Extension `h3-pg` déjà présente dans PostgreSQL 16.

DÉMONSTRATION ET SUITE

Intersession 3 : pré-traitement et géodatabase

Nettoyage tracé

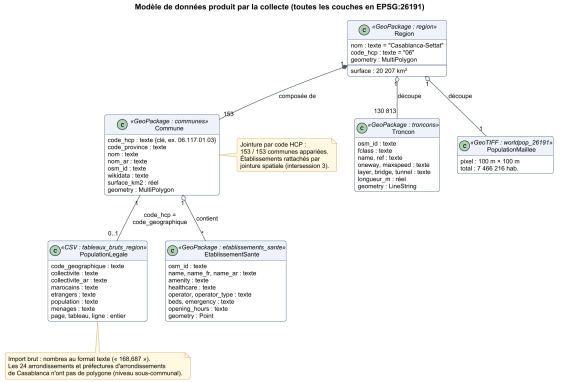
- `ST_MakeValid`, doublons, hors emprise ; rapport avant/après
- Mode `--dry-run` : rapport seul, sans modification
- **Désaccord topologique réel** : interstices et chevauchements entre communes OSM voisines, aujourd'hui refermés par un tampon de ±5 m
- Topologie du réseau routier : nœuds aux intersections, ponts et tunnels

Schéma PostGIS

- Tables `commune`, `population_legale`, `etablissement`, `troncon`, `hexagone`
- Clé étrangère sur le **code HCP**, déjà apparié 153/153
- Import `ogr2ogr`, index spatiaux GIST
- 3 requêtes métier avec `EXPLAIN ANALYZE`
- Base peuplée et dump restaurable

DÉMONSTRATION ET SUITE

Le modèle de données, base du schéma PostGIS


Modèle de données produit par la collecte (toutes les couches en EPSG:26191)
«GeoPackage : region»
Region
nom : texte = "Casablanca-Settat"
code_hcp : texte = "06"
geometry : MultiPolygon
surface : 20 207 km²
1
1
1

Bilan au regard du barème de l'intersession 2

Critère	Points	Preuve présentée
Environnement fonctionnel et script reproductible ($\geq$ 2 sources)	6	5 sources, une commande, reconstruction vérifiée depuis un dossier vide
CRS uniforme et vérifié	3	Contrôle automatique : tout en EPSG:26191, code de sortie 0
`SOURCES.md` et README de provenance complets	3	URL, millésime, licence, CRS, emprise, volume, SHA-256
Capture QGIS de vérification	2	Projet généré par script, capture en EPSG:26191

Merci.

Questions ?

github.com/meryem-souilah/Acces_soins_Region_Casablanca-Settat